

Test for 26 Fall

同学好，欢迎选择南京大学推理与学习研究组。为了进一步了解大家对数学和计算机的掌握情况，并帮助大家具体了解实验室在计算方向的课题，我们准备了实验室目前的课题密切相关的测试题，欢迎**自主选择并尽量完成**，考核时间为**2至4周**，请在这个时间段内提交一份文档和相关代码，请勿早于2周或晚于4周提交。对于没有做出来的题目，可以展示出做过的最优尝试。**严禁使用 AI 工具回答问题（辅助代码编程除外）**。请将完成的文档和代码发送至：`gzben01@gmail.com`，并抄送至：`fanqi@nju.edu.cn`。

1. 在经典强化学习中，state value 的定义通常采用指数型折扣，即对第 k 步后的回报乘以常数折扣系数 λ^k 。现将该折扣系数推广为与步数相关的函数 $\lambda(k)$ ，请给出在此设定下的 state value 与 action value 的定义式及推导过程，并写出对应的 Bellman 方程（state value 形式）。
2. 基于 Thyme-SFT 数据集（请自行下载约 1k 条数据）实现从 SFT 轨迹格式数据到 RL 问答格式数据的转化。以 Qwen-2.5-VL-3B-Instruct 模型为 base model，在该数据集上分别实现基于 PPO [1] 和 GRPO [3] 算法的训练流程。
3. 题目 2 中涉及的强化学习算法分别有什么优势与劣势？请结合具体实现进行分析。
4. 调研 TRPO [2] 论文中提出的两种 rollout 方式，分别结合 GRPO [3] 和 ARPO[4] 的设计，分析它们各自借鉴了哪一种 rollout 方式，并分析相应的设计理由与优缺点。
5. Bonus（非必须，感兴趣的同学可自行完成）：
 - (a) 请在题目 2 中实现的 PPO 基础上实现一个 online filter，使得用于 policy update 的 batch 中，advantage 的方差稳定在指定区间内。同时进行对比实验，分析加入 online filter 前后 reward 曲线的差异及原因。
 - (b) 请在题目 2 中实现的 PPO 或 GRPO 基础上，补充实现题目 4 中 TRPO [2] 提到的相对少见的 rollout 方式。启动训练并与另一种 rollout 方式进行对比实验，分析不同方式在性能与训练稳定性上的差异。

References

- [1] J. Schulman, et al., Proximal Policy Optimization Algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [2] J. Schulman, et al., Trust Region Policy Optimization. In *ICML, 2015*.
- [3] Zhihong Shao, et al., DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. *arXiv preprint arXiv:2402.03300*, 2024.
- [4] Guanting Dong, et al., Agentic Reinforced Policy Optimization. *arXiv preprint arXiv:2507.19849*, 2025.